



СберАвтоподписка: предсказание вероятности целевого действия пользователя

Авторы:

- Александр Журавлев
- Василий Феде
- Нина Кулюлина

Бриф проекта

СберАвтоподписка — это сервис долгосрочной аренды автомобилей для физических лиц. Сервис выступает альтернативой покупке авто или автокредиту — машину выгоднее арендовать, а средства инвестировать.

Компания «СберАвтоподписка» хочет увеличить эффективность сайта: улучшить пользовательский опыт, повысить конверсию, сделать рекламные кампании более результативными. Для этого необходимо создать модель, которая предсказывает вероятность того, что пользователь совершит целевое действие (оставит заявку, закажет звонок и пр.) на сайте.



Задачи проекта

1

Выявить ключевые поведенческие закономерности и возможные факторы принятия решения

2


Создать модель, предсказывающую, совершит ли пользователь целевое действие

3

Интегрировать модель в веб-интерфейс через API

Исходные данные - датасет GA Sessions


- размерность: 1860042 x 18
- отсутствуют полные дубликаты строк
- данные содержат большое количество пропусков (явных и неявных):
99.2% строк имеют пропуски
- в признаке `device_brand` имеются неявные дубликаты



Распределение пропусков в датасете GA Sessions

Исходные данные - датасет GA Hits

- размерность: 15726470 x 11
- отсутствуют полные дубликаты строк
- данные содержат большое количество пропусков:
100% строк имеют пропуски
- признак hit_type имеет только 1 значение



Распределение пропусков в датасете GA Hits

Предобработка данных



Датасеты очищены от пропусков (признаки с большим количеством пропусков удалены, остальные пропуски преимущественно заполнены). Размеры датасетов сократились менее чем на 1%.

Устранены неявные дубликаты в категориальных признаках

Созданы новые признаки:

- `device_screen_resolution` -> `screen_area`, `aspect_ratio`
- `hit_page_path` -> `car_brand`
- `event_action` -> выделен таргет, исходный признак удален

Датасет GA Hits сгруппирован по признаку `session_id` (если в данную сессию было выполнено хотя бы одно целевое действие, значение сгруппированного таргета принимается за True)

На основании предобработанных данных составлен рабочий датасет

Некоторые поведенческие закономерности

Повторные визиты увеличивают вероятность конверсии, но они редки



Разнообразие действий в сессии — признак заинтересованности



Днем целевые действия совершаются чаще, чем в ночное время



Пользователи чаще заходят на сайт с телефона, но выполняют ЦД с десктопа

Чаще на сайт заходят с устройств Apple, но не совершают ЦД

Большинство пользователей из Москвы и СПб, но они редко совершают ЦД

Обучение моделей

Особенности задачи обучения:

- решается задача **бинарной классификации**
- подавляющее большинство признаков - **категориальные**
- имеется выраженный **дисбаланс классов**

Работа с датасетом:

- анализ качества модели производился на **отложенной тестовой выборке**
- из тренировочной выборки при необходимости извлекалась валидационная


Выбор моделей:

- линейная модель:
 - Logistic Regression
- ансамблевые модели:
 - CatBoost
 - Gradient Boosting
 - LightGBM

Выбор метрик:

- **Нельзя** использовать Accuracy
- Используем **ROC-AUC и PR-AUC**

Логистическая регрессия




Качество модели на отложенной выборке
(с учетом подбора гиперпараметров)

0.17

PR-AUC


0.79

ROC-AUC



Оценка важности признаков


CatBoost



Качество модели на отложенной выборке
(с учетом кросс-валидации)

0.24

PR-AUC




Оценка важности признаков

0.87

ROC-AUC

Gradient Boosting



Качество модели на отложенной выборке


0.20

PR-AUC


0.84

ROC-AUC

LightGBM



Качество модели на отложенной выборке (с учетом кросс-валидации)



Оценка важности признаков

0.25

PR-AUC

0.87

ROC-AUC

Наилучшие результаты

Модели CatBoost и LightGBM

0.25

PR-AUC

0.87

ROC-AUC

Дополнительно были произведены эксперименты с обучением нейросети, однако ее метрики не превысили метрики моделей CatBoost и LightGBM.

API - для соло-предсказаний

API (CatBoost) обернут в Docker + UI

Single JSON Batch CSV

JSON с признаками (см. пример внизу)

```
{
  "event_categories_number": 3,
  "hit_number_median": 2,
  "visit_number": 4,
  "month": 5,
  "day_of_week": 3,

  "utm_source": "google",
  "utm_medium": "cpc",
  "device_category": "mobile",
  "device_brand": "apple",
  "device_browser": "chrome",
  "geo_country": "russia",
  "geo_city": "moscow",
  "time_of_day": "evening",
  "top_car_brand": "mercedes"
}
```

Вероятность

0

Predict

Доступ к модели через API:

- Реализован REST API с помощью FastAPI
- Визуальный интерфейс для тестирования модели — Gradio
- Всё приложение упаковано в Docker-контейнер

Поддержка запросов через /predict и веб-интерфейс

API - для нескольких предсказаний

API (CatBoost) обернут в Docker + UI

GA Churn Predictor — CatBoost

Single JSON **Batch CSV**

Загрузите **ДВА** файла: `ga_sessions.csv` и `ga_hits.csv` (сырые данные Google Analytics)

`ga_sessions.csv`

Перетащите файл сюда
- или -
Нажмите для загрузки

`ga_hits.csv`

Перетащите файл сюда
- или -
Нажмите для загрузки

Preview (≤50 строк)

1	2	3
---	---	---

Predict batch

GA Churn Predictor — CatBoost

Single JSON **Batch CSV**

Загрузите **ДВА** файла: `ga_sessions.csv` и `ga_hits.csv` (сырые данные Google Analytics)

`ga_sessions.csv`
`sessions_sample.csv` 4.5 KB ↓

`ga_hits.csv`
`hits_sample.csv` 41.7 KB ↓

Preview (≤50 строк)

top_car_brand_geo_country_1_russia	geo_country_month_russia_10	probabili_
null	null	0
null	null	0
null	null	1
null	null	0
null	null	0
null	null	1
null	null	0
null	null	0
null	null	1

Predict batch

Выводы и перспективы

Модель CatBoost успешно предсказывает целевые действия пользователей СберАвтоподписки.

Ключевые факторы

Количество действий
Месяц визита
Канал привлечения
Тип привлечения
Порядковый номер визита

Высокая точность

Модель достигает
значимых показателей
PR-AUC и ROC-AUC на
валидационных данных.

Дальнейшее развитие

Внедрение модели в реальном
времени для персонализации
предложений и повышения
конверсии.

Репозиторий
проекта



Спасибо за внимание!